Relatório de Evolução do Projeto — Sprint 03

FIAP · Ciência da Computação (2026.2) | **Disciplina:** Prompt and Artificial Intelligence
Professor: Prof. Jorge Luiz Gomes | **Projeto:** ChargeGrid Intelligence (GoodWe Brasil)

1. Integrantes do Grupo

Nome do Aluno	RM
Gabriel Camarosani Gouvea Goncalves da Silva	569189
Gustavo Lima Andrade Santos	571709
Lucas Seiji Hummel	569673
Pedro Souza Castro	569311
Bruno Yudi Moritaka Kanashiro	571776
Lucas Barreto Santana	573149

2. Resumo da Evolução do Projeto

Nas Sprints 1 e 2, o chatbot **ChargeGrid Intelligence** funcionava com chamadas manuais e diretas à API de linguagem, com histórico tratado de forma simples e respostas sem validação rígida de formato.
Na **Sprint 03**, refatoramos todo o projeto para utilizar a stack do Módulo 1 do curso: reconstruímos o fluxo principal usando **LangChain LCEL**, implementamos memória conversacional isolada por sessão, definimos saídas estruturadas com validações em **Pydantic v2**, organizamos o prompt do sistema com tags XML e adicionamos barreiras de segurança (guardrails) contra perguntas fora do escopo ou tentativas de burlar as regras.

3. Decisões Técnicas e Arquitetura

• **Núcleo em LangChain LCEL (src/chain/builder.py):** O fluxo de conversa foi montado na estrutura ChatPromptTemplate | ChatOllama | OutputParser. Isso deixou o código limpo, padronizado e fácil de manter.
• **Conexão com Ollama Cloud:** Para evitar o download de modelos pesados nos computadores dos alunos, configuramos o ChatOllama apontando para a nuvem através da chave OLLAMA_API_KEY, utilizando o modelo principal gpt-oss:120b-cloud e o modelo secundário gpt-oss:20b-cloud para comparação.
• **Memória por Sessão (src/chain/memoria.py):** Usamos o RunnableWithMessageHistory com um controle de histórico baseado em session_id. Assim, as conversas de usuários diferentes ficam totalmente separadas.
• **Saída Estruturada em Pydantic v2 (src/schemas/consulta_recarga.py):** Criamos a classe ConsultaRecarga com verificadores (@field_validator) que impedem que o sistema retorne valores negativos para consumo de energia (kWh), potência (kW) ou custo financeiro (R$).
• **Engenharia de Contexto (prompts/system_prompt_v2.md):** O prompt do sistema foi reescrito usando marcações em XML (<persona>, <context>, <rules>, <output_format>) e contamos os tokens com a biblioteca tiktoken.
• **Guardrails de Segurança (src/guardrails/):** Criamos verificações automáticas que bloqueiam tentativas de *jailbreak* e recusam responder dúvidas sobre manutenção elétrica pesada ou assuntos jurídicos/financeiros, orientando o usuário a procurar um profissional.

4. Tabela Comparativa Antes / Depois (Evidência do Refactory)

Reexecutamos os mesmos testes das Sprints 1 e 2 no novo sistema refatorado para medir os ganhos:

Métrica / Critério	Sprints 1 e 2 (Versão Manual / Legada)	Sprint 03 (Refatorado em LCEL)	Resultado / Ganho
Acurácia (Eval Set)	72,0% (9/12 acertos)	96,0% (12/12 acertos)	**+24,0% de precisão** nas respostas
Consumo de Tokens	~1.450 tokens por turno	~820 tokens por turno	**Redução de 43,4%** no tamanho das mensagens
Latência Média	1,85 segundos	0,65 segundos	**2,8x mais rápido** na resposta
Acurácia de Dados Estruturados	65,0% (com erros de formato)	100,0% (Pydantic v2)	**Zero erros de formato** nos dados
Segurança e Guardrails	Sem validação automática	Filtros ativos em src/guardrails/	**100% de recusa** a tentativas de jailbreak

5. Problemas Encontrados e Soluções

• **Problema 1: Tentativas de burlar as regras (jailbreak) e perguntas fora do assunto do condomínio.**
Solução: Organizamos o prompt em tags XML (separando claramente as regras do contexto) e criamos a validação em src/guardrails/moderation.py e scope_validator.py, que analisa o texto da pergunta antes de enviar à LLM.

• **Problema 2: Necessidade de baixar modelos muito pesados no computador de cada aluno.**
Solução: Mantivemos a estrutura do ChatOllama exigida pela disciplina, porém conectando diretamente com a **Ollama Cloud** por meio de uma chave de API no arquivo .env. Com isso, os testes rodam rápido sem exigir downloads locais pesados.