Relatório de Evolução do Projeto — Sprint 04

ChargeGrid Intelligence · FIAP × GoodWe Brasil · Prompt and Artificial Intelligence · 2026.2

1. Resumo da evolução

- **Sprints 1 e 2:** respostas manuais em Python e histórico simples; os dados dos carregadores ficavam escritos no código.
- **Sprint 03:** refatoração para LangChain LCEL com prompt versionado, memória por sessão, saída estruturada (Pydantic v2) e guardrails; os dados ainda ficavam fixos no prompt.
- **Sprint 04:** RAG **medido e com interface**. Base de 5 PDFs indexados em ChromaDB persistente com `nomic-embed-text`; busca híbrida (embeddings + BM25); respostas só com o contexto recuperado, com citação de documento, página e seção; avaliação em 25 casos ao longo de 6 iterações; interface web em HTML, CSS e JavaScript; comparação de 2 modelos e 2 provedores.

2. Pipeline RAG

PyMuPDFLoader → RecursiveCharacterTextSplitter (700/100, por seção, com cabeçalho `[documento | seção]`) → `nomic-embed-text` → ChromaDB (cosseno, persistente) → busca híbrida (embeddings + BM25, fusão RRF, k=6) → corte de relevância (0,55) → sanitização → prompt RAG v3 → LLM → resposta com `[S#]` validado.

Segurança: bloqueio de entrada maliciosa antes da busca; sanitização de instruções escondidas nos documentos; contexto tratado como dado (prompt v3); citação validada contra os trechos enviados; recusa de risco elétrico, jurídico e financeiro.

Interface: FastAPI + HTML/CSS/JS puros. A resposta traz chips `[S1]` clicáveis que abrem o trecho da base, com documento, página, seção e relevância; mostra também o que foi recuperado quando o assistente recusa.

3. Comparativo antes/depois

Métrica	Sprints 1/2 (original)	Sprint 04, 1ª iteração (baseline v1)	Sprint 04, final (iteração 6)
Faithfulness (fidelidade ao contexto, 0–1)	não medida	1.00	1.00
Answer relevancy (0–1)	não medida	0.69	0.83
Trecho com a resposta entre os recuperados	sem recuperação (dados fixos no prompt)	78%	100%
Documento esperado entre os recuperados	sem recuperação	83%	100%
Perguntas respondíveis recusadas por engano	não medida	17%	6%
Respostas com citação de fonte	0% (não citava)	100%	100%
Recusa correta fora do contexto	não medida	100%	100%

Evolução por iteração (mesmo eval set de 25 casos, mesma rubrica):

Iter.	Configuração	Faithfulness	Answer relevancy	Contém esperado	Hit fonte	Hit trecho	Recusa correta	Recusa indevida
1	v1 · densa, k=4, chunks 700/100	1.00	0.69	0.83	83%	78%	100%	17%
2	v2 (citação + recusa fixa)	1.00	0.69	0.96	83%	78%	100%	28%
3	v3 (XML, anti-injection)	1.00	0.69	0.96	83%	78%	100%	28%
4	v3 + chunks 400/60	1.00	0.69	0.96	83%	78%	100%	28%
5	v3 + busca híbrida, k=4	1.00	0.75	0.90	94%	89%	100%	17%
6	v3 + busca híbrida, k=6	1.00	0.83	0.91	100%	100%	100%	6%

- **Iteração 2 (prompt v2):** a citação obrigatória elevou `contém esperado` de 0,83 para 0,96, mas as recusas indevidas subiram de 17% para 28%.
- **Iterações 3 e 4 (prompt v3, chunks de 400):** sem mudança nas métricas. A v3 vale pela segurança; os chunks menores só dobraram a latência.
- **Iterações 5 e 6 (busca híbrida):** o ganho principal. `answer_relevancy` 0,69 → 0,83, trecho certo recuperado em 100% dos casos e recusa indevida 28% → 6%.

Métrica: rubrica manual de 0 a 1 aplicada por LLM juiz (equivalente às definições de faithfulness e answer relevancy do RAGAS), documentada em `docs/relatorio_rag.md`. Números de `evals/results/*.json`.

Modelos e provedores (detalhes em `docs/relatorio_modelos.md`): na busca final, `gpt-oss:120b` e `gpt-oss:20b` empataram em recusa indevida (6%) e fidelidade (1,00); o 120b deu respostas mais completas (`contém esperado` 0,91 contra 0,85). Com busca só por embeddings, o Gemini 2.5 Flash ficou abaixo do gpt-oss:120b em fidelidade (0,93 contra 1,00) e foi cerca de 6 vezes mais lento.

Limitações: eval set pequeno (18 casos respondíveis; um caso vale 5,6 pontos percentuais); a configuração final foi escolhida olhando as falhas do mesmo eval set (números otimistas); o juiz é o próprio modelo avaliado.

4. Problemas encontrados e soluções

1. **Trecho com a resposta fora do top-k.** Com `nomic-embed-text` todos os scores ficavam entre 0,58 e 0,76 e a resposta

aparecia nas posições 8 a 18. *Solução:* busca híbrida (BM25 + embeddings) e k=6; recusa indevida de 28% para 6%.
2. **Pergunta curta contaminada pela anterior.** "Quanto custa uma hora de recarga no CG-02?" era tratada como continuação e recebia contexto errado. *Solução:* detectar continuações só por marcadores ("e...", "ele", "isso") ou até 3 palavras; casos de regressão no eval set.
3. **Limiar de relevância não separa dentro/fora do contexto.** Perguntas do mesmo assunto sem resposta na base (preço, garantia) pontuam mais que uma pergunta de futebol. *Solução:* corte conservador (0,55) e recusa pelo prompt v3. As 7 perguntas que deviam ser recusadas foram todas recusadas (entre bloqueio de entrada e prompt).
4. **Embeddings na Ollama Cloud retornaram 401** (o chat funcionava). *Solução:* embeddings no Ollama local e geração na nuvem.
5. **Chave antiga do terminal sobrepunha o `.env`.** *Solução:* `override=True` e script de diagnóstico com chave mascarada.
6. **`hit da fonte` escondia a falha de busca.** *Solução:* nova métrica `hit do trecho`.
7. **Filtro anti-injection e listas numeradas.** Texto legítimo acionava o filtro ou virava "seção"; resolvido ao redigir a base de forma controlada e testar isso automaticamente.

5. Grupo

Nome	RM
Gabriel Camarosani Gouvea Goncalves da Silva	569189
Gustavo Lima Andrade Santos	571709
Lucas Seiji Hummel	569673
Pedro Souza Castro	569311
Bruno Yudi Moritaka Kanashiro	571776
Lucas Barreto Santana	573149

Repositório: https://github.com/gabrielcggs/SPRINT-2026-IA